Machine Learning e Visão Computacional - Turma 05

Mini-Projeto Avaliativo - Módulo 1 - Semana 07

SUMÁRIO

1 CONTEXTUALIZAÇÃO 1
2 DESAFIO 2
3 RESULTADOS ESPERADOS (ENTREGA) 3
- Script Python (main.py, funcoes.py ou .ipynb) 3
● Arquivo README.md (Documentação) 4
● Arquivo report.md (Relatório) 4
4 REQUISITOS DAS TAREFAS 4
5 GRAVAÇÃO DE VÍDEO 5
6 CRITÉRIOS DE AVALIAÇÃO 5

1 CONTEXTUALIZAÇÃO

A Festa em Cena é uma rede fictícia que vende fantasias e acessórios para o Halloween pelos canais Mercado, Loja física e Web. Mercado representa vendas para consumidores finais nos caixas de supermercados parceiros; Loja física representa lojas próprias; Web representa pedidos feitos pelo site. A empresa precisa organizar seus registros e entender como os pedidos variam por canal e período.

Antes de interpretar os dados ou utilizá-los em Machine Learning, é necessário verificar informações ausentes, textos inconsistentes e datas inválidas. A qualidade dos dados influencia os resultados das análises e dos modelos. Entretanto, limpeza não garante, sozinha, evitar overfitting ou underfitting: representatividade, escolha do modelo e avaliação também importam.

Nesta atividade, você aplicará lógica de programação para ler, organizar e explorar um único CSV. A base contém 1.500 pedidos distintos de agosto a novembro de 2024 e de 2025. Cada linha representa um pedido de um único produto, que pode conter várias unidades. Os dados são fictícios e incluem problemas intencionais para aprendizagem.

Base de Dados (.csv): halloween_vendas.csv, que pode ser feito download aqui https://github.com/Machine-Learning-Visao-Computacional-T5/python_exercises/blob/main/data_analysis/arquivo_mini_projeto/halloween_vendas.csv . Os horários são locais de São Paulo, sem fuso explícito. O Halloween é considerado em 31 de outubro de cada ano.

2 DESAFIO

A equipe da Festa em Cena identificou categorias vazias, pontuações indevidas, diferenças na escrita dos canais, quantidades inválidas, preços ausentes e algumas datas inválidas. A gestão quer um relatório simples antes de comparar os períodos de venda.

Sua missão como Analista de Dados Júnior é desenvolver um programa em Python, usando as bibliotecas padrão, como csv, re e datetime (ou outras de sua preferência). Utilize variáveis, listas, dicionários, condicionais, laços e funções. Utilize Pandas para processar os dados.

As tarefas técnicas específicas a serem cumpridas são:

1. **Validação e Tratamento de Dados Ausentes:** Leia halloween_vendas.csv com usando `pd.read_csv()`, da biblioteca Pandas, e armazene os dados em um *DataFrame*. Preencha categoria vazia com a string "sem categoria". Verifique quantidade (inteiro maior que zero) e preco_unitario (preenchido e não negativo). Marque ou separe registros com problemas, sem inventar valores. Justifique sua regra nos comentários e no README. Conte os problemas por campo e o total de pedidos afetados, sem somar ocorrências que podem se sobrepor.
2. **Padronização de Strings e Regex:** Utilize .strip() e .lower() na coluna categoria e aplique obrigatoriamente re.sub() para retirar pontuações indevidas, preservando letras e espaços significativos. As categorias preenchidas deste CSV usam letras sem acentos. Se o resultado ficar vazio, use "sem categoria". Padronize canal_venda para Mercado, Loja física e Web. Conte categorias vazias preenchidas e categorias não vazias alteradas separadamente.
3. **Lógica de Regra de Negócio (Filtros e Validação):** Com condicionais, investigue se todos os registros com data_entrega vazia têm status_pedido igual a Cancelado. Conte separadamente pedidos sem entrega e cancelados e pedidos sem entrega com outros status. Mostre até três exemplos do segundo grupo. Se houver um contraexemplo, a hipótese é falsa na base. Não altere o status nem invente datas de entrega.
4. **Formatação Temporal (Datetime):** Converta data_venda com datetime.strptime(), do formato "2025-10-12 14:35:00". Preserve o texto original, extraia ano, mês, dia e hora e crie uma apresentação brasileira com strftime(), como "12/10/2025". Conte e marque ou separe datas inválidas ou vazias, permitindo continuar o processamento. Não substitua pela data de hoje.
5. **Relatório de Status Manual e Exploração:** Exiba total de linhas lidas, categorias preenchidas e padronizadas, problemas numéricos, datas inválidas e total de cancelados, além dos dois grupos sem data de entrega. Conte pedidos por canal

usando registros com canal reconhecido; por ano-mês, use registros com data_venda válida. Nessas duas contagens, inclua todos os status e informe exclusões. Não agrupe apenas por mês, pois isso mistura anos. Produza duas descobertas: uma por canal e outra por período, com números, interpretação e limitação. Essas contagens representam pedidos registrados, não receita ou vendas concluídas

6. **Relatório e insights:** Crie um arquivo chamado `report.md` no repositório GitHub de entrega. Apresente um resumo dos principais achados e insights, apoiados nos resultados da sua análise, com 1.500 a 3.000 caracteres, incluindo espaços. Utilize uma ferramenta de IA para conferir a contagem de caracteres do texto final.

3 RESULTADOS ESPERADOS (ENTREGA)

Você deverá organizar e submeter o projeto contendo os seguintes entregáveis:

- **Vídeo de apresentação do problema/solução (5 a 7 minutos)**

Entregue um vídeo explicando como você resolveu o projeto e o que encontrou na análise. Compartilhe a tela para mostrar o código e os resultados, abordando:

- **Organização da solução:** como dividiu o código em funções e quais são suas responsabilidades.
- **Leitura e tratamento dos dados:** como leu o CSV, realizou as conversões necessárias e identificou ou tratou registros com problemas.
- **Decisões tomadas:** quais regras utilizou e por quê, mostrando exemplos de aplicação de condicionais, laços, expressões regulares e datas.
- **Execução e resultados:** execute a solução e explique os principais resultados, problemas encontrados nos dados e conclusões da análise.
- **Aprendizados e dificuldades:** comente o que aprendeu e como resolveu as principais dificuldades.

O objetivo é demonstrar que você compreende a solução entregue. Não basta ler o código: explique, com suas palavras, como ele funciona e o que os resultados significam.

- **Script Python (main.py, funcoes.py ou .ipynb)**

O código deve ser modular, dividido em funções com parâmetros e retornos adequados, e comentado para explicar as decisões. Demonstre a aplicação prática de:

- Manipulação do csv com Pandas, preservando o arquivo original. Os campos são lidos como texto e precisam de conversão quando usados como números ou datas. Utilize vírgula como separador e encoding="utf-8" na leitura.
- Dataframes, revisão de nulos, limpeza e formatação de dados.
- Análise de dataframes.

- Funções definidas com def, Expressões Regulares (re) e datetime quando necessário. A solução pode ser um script .py ou notebook .ipynb, sempre com Python. Gráficos, margem, treinamento de modelos e união de arquivos não são exigidos.

- **Arquivo README.md (Documentação)**

  Um arquivo de texto explicativo escrito em Markdown no repositório contendo:

  - Descrição do Projeto: Explique o problema da Festa em Cena, o objetivo do programa, o significado de uma linha e de quatro colunas à sua escolha. Documente as regras adotadas para textos, valores e datas. Custos e descontos estão no CSV, mas seu uso é opcional.
  - Guia de Execução e Resultados: Explique como abrir e executar o projeto, onde colocar o CSV e quais arquivos são necessários. Apresente os resultados, a conclusão sobre entrega sem data e duas descobertas com evidência numérica, interpretação e limitação. Não confunda unidades com pedidos ou a base fictícia com o mercado real.

- **Arquivo report.md (Relatório)**

  Um arquivo de texto explicativo escrito em Markdown no repositório contendo:

  - Relatório e *insights* apresentando um resumo dos principais achados e insights, apoiados nos resultados da sua análise, com 1.500 a 3.000 caracteres, incluindo espaços. Utilize uma ferramenta de IA para conferir a contagem de caracteres do texto final.

Regra de Submissão: Crie um repositório público no GitHub com os arquivos do código (extensão .py ou .ipynb), README.md, report.md e halloween_vendas.csv. Registre o desenvolvimento com commits de mensagens compreensíveis. Envie o link no AVA, na tarefa "Módulo 1 - Mini-Projeto Avaliativo", até o prazo publicado pela coordenação. A organização dos commits fica a critério do estudante. Consulte no AVA se a realização será individual ou em grupo.

Submeta o vídeo também no AVA.

4 REQUISITOS DAS TAREFAS

Para apoiar a sua organização e o gerenciamento de tempo, recomenda-se dividir a execução do projeto nas seguintes etapas (Sprints):

- **Sprint 1 (Configuração e Ingestão):** Crie o repositório, organize a pasta e leia o CSV. Confira o total de linhas e mostre três registros. Entrega parcial: leitura funcionando e significado dos dados explicado.
- **Sprint 2 (Transformação de Strings):** Crie funções e ou use métodos para limpar categorias com, por exemplo, .strip(), .lower() e re.sub(), preencher vazios e padronizar canais. Entrega parcial: exemplos de antes e depois e contagens de correções.
- **Sprint 3 (Nulos e Validação):** Verifique quantidade e preço, marque ou separe problemas e documente a regra. Entrega parcial: contagens por campo e por pedido, com processamento que continua após erros.
- **Sprint 4 (Regras de Negócio e Datas):** Converta timestamps, extraia suas partes, investigue entrega sem data e conte pedidos por canal e ano-mês. Entrega parcial: hipótese respondida e duas descobertas sustentadas por números.
- **Sprint 5 (Relatório e Documentação):** Organize as funções/células e o relatório, finalize o README.md e report.md com a reflexão sobre a análise exploratória, execute do início e confira o **repositório público** antes de enviar o link no AVA.

5 GRAVAÇÃO DE VÍDEO

Além do desenvolvimento deste sistema você deverá gravar um vídeo, com tempo **máximo de 7 minutos**, abordando os seguintes questionamentos:

- Qual o objetivo dessa análise? E demonstração de funcionamento.
- O que deve ser realizado para executar a análise? Quais pontos são importantes.
- Como você organizou as tarefas antes de começar a desenvolver?
- Quais as *branches* você criou e quais os objetivos para cada uma?
- Você acha que faltou algo no seu código que você poderia melhorar?

6 CRITÉRIOS DE AVALIAÇÃO

A tabela abaixo apresenta os critérios que serão avaliados durante a correção do projeto. O mesmo possui variação de nota de 0 (zero) a 10 (dez) como nota mínima e máxima, e possui peso de 25% sobre a avaliação do módulo. Neste item devem ser listadas tarefas em formato de Sprint para que os estudantes possam realizar durante o período de execução do Mini-projeto Avaliativo. Seguindo as orientações e critérios disponibilizados neste arquivo.

Serão desconsiderados e atribuída a nota 0 (zero) os projetos que apresentarem plágio de soluções encontradas na internet ou de outros colegas. Lembre-se: Você está livre para utilizar outras soluções como base, mas não é permitida a cópia. Resoluções entregues em Excel e/ou Google Sheets e/ou similares também serão desconsideradas.

Documentação do Projeto			
N°	Critério de Avaliação	0	2,00
1	**Versionamento e Documentação**	Não entregou o repositório no GitHub contendo os arquivos organizados e um README.md explicativo com a reflexão teórica obrigatória sobre ML e qualidade de dados.	Entregou o repositório no GitHub contendo os arquivos organizados e um README.md explicativo com a reflexão teórica obrigatória sobre ML e qualidade de dados.
2	**Vídeo**	Não fez vídeo	Entregou o vídeo explicando os itens solicitados no item 5.

Desenvolvimento do Projeto				
N°	Critério de Avaliação	0	0,5	1,0
2	**Manipulação de Arquivos CSV**	Não realizou a leitura e extração dos arquivos de dados usando `pd.read_csv()`, da biblioteca Pandas.	Realizou a leitura e extração dos arquivos de dados de forma **parcialmente** usando `pd.read_csv()`.	Realizou a leitura e extração dos arquivos de dados de forma estruturada e nativa dados usando `pd.read_csv()`.
3	**Tratamento de Nulos e Condicionais**	Não implementou a lógica (if/else) para preencher categorias vazias com "Sem Categoria" e não tratou os nulos das dimensões físicas, justificando a escolha.	Implementou parcialmente a lógica (if/else) para preencher categorias vazias com "Sem Categoria" e tratou parcialmente os nulos das dimensões físicas, justificando a escolha.	Implementou a lógica (if/else) para preencher categorias vazias com "Sem Categoria" e tratou corretamente os nulos das dimensões físicas, justificando a escolha.

4	**Regras de Negócio e Datas**	Não validou a regra dos pedidos cancelados separando os registros, e não converteu com sucesso a string de data de aprovação utilizando o módulo datetime.	Validou parcialmente a regra dos pedidos cancelados separando os registros, e converteu parcialmente a string de data de aprovação utilizando o módulo datetime.	Validou a regra dos pedidos cancelados separando os registros, e converteu com sucesso a string de data de aprovação utilizando o módulo datetime.
5	**Limpeza de Strings**	Não aplicou corretamente os métodos de string e o módulo re (Regex) na padronização das categorias.	Aplicou parcialmente os métodos de string e o módulo re (Regex) na padronização das categorias.	Aplicou corretamente os métodos de string e o módulo re (Regex) na padronização das categorias.
6	**Report.md**	O código não possui o report.md	Possui report.md, mas não atende aos requisitos.	O Report.md atende aos requisitos.